

인컴 회지로 챗봇 만들기

파인튜닝 vs RAG — 코랩 무료 GPU 하나로 둘 다

2학기 첫 수요일 · 2026. 9. 23 (수) 18:15
김유현 (46기 유니코사)



unisloth



FAISS



ChatGPT는 인컴을 모른다

인하대 인컴 수요모임이 뭐야?

아마 인하대 중앙 컴퓨터 동아리 '인컴(INCOM)'의 수요모임을 말하는 것 같아.

- **인컴(INCOM)**은 인하대학교 중앙동아리 중 연구분과의 컴퓨터 동아리야. 현재 동아리 목록에도 컴퓨터 분야로 등록되어 있어. 
- 인컴은 프로그래밍·컴퓨터 관련 스터디와 활동을 하는 동아리로 보이고, 과거 인컴 앱 설명에도 선배가 함께 스터디했다는 내용이 확인돼. 
- **'수요모임'**은 이름 그대로 보통 수요일에 정기적으로 모이는 인컴 내부 모임/활동을 가리키는 표현으로 보이는데, 공개된 자료에서는 정확한 현재 운영 방식이나 프로그램까지는 확인되지 않았어.

혹시 **"인컴 수요모임에 들어가면 뭘 하는지 / 신입도 참여 가능한지 / 분위기가 어떤지"**가 궁금한 거라면, 그쪽으로 더 찾아볼게.

   출처

- 웹 검색까지 붙여도 "운영 방식은 확인되지 않았어"
- 회지는 인터넷에 없다. 모델도, 검색도 못 본다
- 모르면 다행. 그럴듯하게 지어내면 사고

오늘의 질문

우리 문서를 모델이 알게 만들려면?

2026. 9. 16 chatgpt.com, 비로그인

INCOM 수요모임 · 2026.09.23

외우게 하거나, 찾아보게 하거나

외우게 하기 — 파인튜닝

QA 200쌍 → LoRA 학습

시험 전날 벼락치기. 가중치를 조금 바꾼다

임베딩 → FAISS 검색

오픈북 시험. 모델은 그대로, 자료를 찾아 붙인다

찾아보게 하기 — RAG

회지 docx

회칙 + 행사 후기 31편

전처리

문단 326줄 → 청크 53개

대결

같은 질문 5개
원본 / 파인튜닝 / RAG

LoRA

입력 토큰

Embedding

Transformer block × 36

Attention (Q K V O)



학습

MLP (gate up down)



학습

...블록 36개 모두 같은 구조

⋮


LM head

다음 토큰

얼림 (frozen) — 원본 40억 파라미터 그대로

학습 — 작은 행렬 A·B만 (LoRA 어댑터)

$$h = W \cdot x + B \cdot A \cdot x$$



- d는 수천(hidden size), r은 16. $r \ll d$ 라 B·A는 W와 크기가 같지만 실제 숫자는 $2 \cdot d \cdot r$ 개뿐
- 학습이 끝나면 $W + B \cdot A$ 를 합쳐도 되고, B·A만 따로 저장해 어댑터로 나눠 써도 된다 (수십 MB)

~1%

학습하는 파라미터
($2 \cdot d \cdot r \div d^2$)

4bit

원본 W를 압축해 올림
(QLoRA, 4B $\approx$ 3GB)

16GB

코랩 T4 메모리
모델+어댑터+학습상태



unisloth

LoRA 학습을 빠르고 가볍게. 무료 T4에서 4B 모델이 돌아가는 이유

2×

더 빠른 학습

GPU 커널을 직접 최적화

-50~70%

메모리 절약

같은 GPU에 더 큰 모델·긴 문장

3줄

바뀌는 코드

HuggingFace·TRL 방식 그대로

```
from unsloth import FastLanguageModel
model, tokenizer = FastLanguageModel.from_pretrained("unsloth/Qwen3.5-4B", load_in_4bit=True)
model = FastLanguageModel.get_peft_model(model, r=16, lora_alpha=16) # LoRA 어댑터 부착
trainer = SFTTrainer(model=model, train_dataset=ds, args=SFTConfig(...)) # 학습은 TRL 그대로
trainer.train()
```

오픈소스 · Llama, Qwen, Gemma 등 500+ 모델 · github.com/unslothai/unsloth

RAG



- 자료가 바뀌면 파일만 바꾼다. 다시 학습 없음
- 검색이 틀리면 답도 틀린다 → 청크를 어떻게 나누느냐가 절반

노트북

colab.research.google.com · 런타임 유형: T4 GPU

1	전처리	docx → 청크 53개	8분
2	QA 데이터	청크 → 질문-답 200쌍	4분
3	Unsloth 학습	LoRA 붙이고 학습	20분
4	RAG	임베딩 → FAISS → 답변	13분
5	대결	같은 질문 5개, 세 가지 답	12분



Qwen3.5-4B (2026.02) · Qwen3-Embedding-0.6B · FAISS · Colab T4 16GB. 전부 무료

INCOM 수요모임 · 2026.09.23

파인튜닝은 어떻게 말할지를, RAG는 무엇을 말할지를 준다.

실전에서는 둘을 같이 쓴다 — RAG로 사실, 가벼운 파인튜닝으로 말투.

노트북 · 데이터 · 슬라이드

github.com/2026-INCOM/incom-hoeji-chatbot

(Open in Colab 배지 → 바로 실행)

부록 — 왜 파인튜닝은 말투만 배우고 사실은 못 외우나

소량 파인튜닝은 '꺼내는 법'을 배운다

- LIMA (Meta, 2023): 정성 들여 고른 예시 1,000개만으로 SFT해도 응답의 형식과 말투가 확 달라짐. 저자들의 해석은 '지식과 능력은 사전학습에서 이미 배웠고, SFT는 그걸 어떤 형식으로 꺼낼지를 가르칠 뿐' (Superficial Alignment Hypothesis)
- Fine-Tuning or Retrieval? (Ovadia et al., 2023): 새 지식 주입은 RAG가 파인튜닝을 일관되게 이김. 파인튜닝은 같은 사실을 여러 문장으로 바꿔 증강했을 때만 개선
- LoRA Learns Less and Forgets Less (Biderman et al., 2024): LoRA는 전체 파인튜닝보다 새 지식을 확실히 덜 배우고, 대신 원래 능력을 덜 잊음. 오늘의 '1% LoRA'가 못 외우는 건 구조적으로 당연

그럼 사전학습은 어떻게 지식을 가중치에 넣었나

- 같은 사실이 다양한 표현으로 아주 여러 번 나와야 한다. 웹 규모 사전학습은 이 조건을 저절로 만족한다
- Physics of LMs 3.1 (Allen-Zhu & Li, 2023): 가상 인물 전기로 통제 실험. 한 정보가 한 문장으로 한 번만 나오면 문장을 통째로 외울 뿐 '생일이 언제?'에 답 못 함. 표현·순서·서술자를 바꾼 여러 버전을 넣어야 QA로 꺼낼 수 있는 지식이 됨
- Physics 3.3 (2024): 노출이 충분하면 파라미터당 약 2비트 저장, 노출 100회 수준이면 절반 이하. 지식은 '본 횟수'에 비례
- Reversal Curse (Berglund et al., 2023): 'A는 B의 아들'만 배우면 'B의 아들은?'에 답 못 함. 지식이 표현 방향에 묶여 저장된다는 증거
- 오늘의 QA 200쌍 × 3 epoch = 사실당 한두 표현, 세 번 노출. 지식이 되기엔 부족하고 말투만 남는다. 정말 넣으려면 사실당 수십 표현으로 증강 + 전체 파인튜닝/continued pretraining + 더 많은 epoch (망각 위험)